

第一人称健身识别

从 Ego4D 到可承诺的用户价值

行业研究与产品分层 | 2026-06-26

vertical-fitness

一句话结论

第一人称健身识别已经足以稳定产出“训练发生了什么”的低到中精度价值，但还不足以仅凭一枚胸前单目相机，可靠地判定所有动作、精确次数与动作质量。产品不该把技术能力压成一个“识别成功/失败”的开关，而应把输入条件升级成一套第一人称精度阶梯：默认从训练日志和计划约束中获得可用价值；在用户愿意增加第一人称双目/双下视相机、IMU 或少量标记时，再逐级兑换更高精度的识别、计数和有限的动作反馈。

一、先校正研究对象：Ego4D 是起点，不是健身答案

导师提到的“ego 数据集”值得从 Ego4D 开始看，但它回答的是“第一人称感知整体发展到哪里”，不是“健身动作识别已经训练好了没有”。Ego4D 由 Meta 等机构发布，是大规模自然第一人称视频与 benchmark：官方目前描述为 3,600+ 小时、926 位佩戴者、74 个地点、9 个国家；任务覆盖情景记忆、手和物体、预测、音视频说话人与社交交互。Ego4D 官方介绍

它对本项目最有价值的不是某个可直接调用的“健身分类器”，而是三点研究范式：

1. 长、连续、真实世界的视频必须先做时间定位。Ego4D 的 Moment Queries 就是先问“什么时候发生了某件事”，再定位时间窗口。对应到健身，不应先对整段训练强行给一个动作名，而应先定位训练、休息、移动、换器械等状态。

2. 第一人称不是普通第三人称视频的换皮。佩戴者自身身体通常不完整入镜，运动还会带来强烈相机自运动；对手、器械、局部姿态和时间连续性建模，往往比“看见全身做动作”更重要。

3. 多模态与时间同步是研究前沿的常态。Ego4D 部分样本包含音频、眼动、立体、三维扫描或多台同步穿戴相机；这不是说产品必须一次做齐，而是说明单一 RGB 不是研究界默认的终局输入。

所以正确的接法是：用 Ego4D 学习第一人称长视频的任务拆解、数据采集与评测方法；不把它当健身垂类训练集。

二、纵轴：第一人称动作理解如何走到健身场景

1. 第一阶段：从“看手和物”开始

早期第一人称研究主要解决手、物体与短动作。原因很朴素：头戴或胸前摄像头天然看得到手和正在操作的物体，却很难看全自己。研究也很早发现，相机随身体晃动会让传统光流与轨迹特征误把自运动当动作；因此物体、交互关系、局部手势通常比全画面运动更可靠。第一人称动作研究综述

健身恰好是这条路线的困难反例：许多关键差别发生在用户身体上，而不是某个被手拿住的小物体上。坐姿推胸和划船都可能面对器械、双手握把、身体相对固定；胸前视角容易只看见把手和局部器械。于是“识别器械”很有用，却不能直接等于“识别动作”。

2. 第二阶段：Ego4D 把问题扩大为连续生活流

2021-2022 年，Ego4D 将研究从短剪辑推向长时第一人称生活流。它把任务拆成记忆检索、手物互动、未来预测、音视频交互与社交理解，而非声称一个模型可以完整理解佩戴者的一切。Ego4D 论文页

这条路线对健身产品的启发是架构性的：动作名、边界、次数和质量不是同一种问题。连续状态切分可以用低成本时序/音频/IMU 做；器械与动作大类适合视频语义模型；精确次数适合周期信号；质量则要先判断“此视角是否看得到关键技术点”。把它们压进一次 VLM 调用，表面简单，实际不可评估也不可控。

3. 第三阶段：Ego-Exo4D 显示了“多视角训练、单视角推理”的价值

Ego-Exo4D 将同步第一人称与多个第三人称视角放进同一数据集，并配套 7 通道音频、IMU、眼动、SLAM 相机与三维环境信息。其论文明确把难点归为极端视角变化、遮挡、头部运动和身体部位不在视野内；同时提出一个很现实的设置：训练时可用同步 ego/exo 数据，测试时仍只给第一人称视频。Ego-Exo4D 数据集文档 CVPR 2024 论文

这对产品路线的价值在于看清盲区，而不是复制其外部机位：产品端仍只用第一人称；多相机的意义应限制为佩戴设备自身的双目或双下视角。研究中的同步外视角可以帮助学界建立真值，却不是 vertical-fitness 可以依赖的用户输入。

4. 2024：EgoExo-Fitness 终于把问题正面放到健身上

EgoExo-Fitness 是与本项目最贴近的公开研究。它采集同步的第一人称与固定第三人称健身视频，包含动作边界、准备/执行/放松等子阶段、技术要点核验、自然语言点评与质量分数。数据规模为约 31 小时、1,248 个跨视角动作序列、6,211 个单动作、12 类健身动作；它特别用前向和下视的头戴相机捕捉更多身体细节。EgoExo-Fitness 论文

它最重要的研究结果不是某一个漂亮的百分比，而是研究设计本身承认：想回答“做什么、何时做、做得怎么样”三件事，需要不同标注与不同视角。论文也直言，既有全身动作数据主要来自固定第三人称相机；第一人称全身理解仍缺少成熟数据与充分探索。换句话说，业界已经证明这是可研究、可局部落地的方向，但尚未证明“消费级单目第一人称相机可通杀健身动作质量”。

三、横轴：四条可行路线分别能做到什么

路线	用户额外成本	最适合稳定解决的问题	不应承诺的问题	在本项目中的定位
单目第一人称 RGB + 音频	无	是否在训练、粗器械/动作大类、训练时长、训练片段、可见的环境与教练口令	全动作覆盖、细粒度姿态、精确次数、动作质量	默认底座
RGB + IMU	一枚设备已有或低增量	运动/休息边界、周期性、节奏、躯干类计数、跨视觉遮挡的连续性	器械和具体动作名称、关节角度质量	首要增强项
第一人称双目/双下视相机	硬件、功耗、标定成本	深度、器械距离、手-器械几何、近场可见性、局部姿态稳定性	被遮挡的腿、背部、全身对齐和每个动作的质量判定	为特定高价值场景探索，不是第一版前提

路线	用户额外成本	最适合稳定解决的问题	不应承诺的问题	在本项目中的定位
用户标记 + 训练计划约束	数秒交互	极大缩小候选集、消除器械/动作歧义、校正漏检和错检	用户从未声明、画面也不可见的细节	现在就该做的产品能力

1. 默认单目路线：价值不是“万能教练”，而是训练上下文

当前仓库的 Gemini 原生视频实测已经表明：在一条 38 秒胸针视角视频中，360p/2fps 加音频能正确识别绳索三头下压；Gemini 原生视频调用也正确给出了约 7 次，并引用了教练口令。但同一材料也显示，换模型、分辨率或输入组织后，分段和次数会漂移；VLM 和简单音频能量计数都并不稳定。仓库实验记录

因此默认模式的产品价值应该是：

- 自动生成训练日志初稿：训练时长、器械区域、训练片段、动作大类和待确认候选；
- 将视频、音频和时间线变成“可复核的证据”，而不是仅给一个黑盒动作名；
- 用 UNKNOWN、大类或候选集诚实承接不可见的情况；
- 让用户只修正高价值的 1-2 个错误，系统据此完成本次总结与个体化校正。

这已经能帮助用户减少记录负担、追踪训练连续性、回看教练口令、估算训练负荷与发现训练计划偏离。它不是低配版的动作纠错。

2. RGB + IMU：最值得优先投入的组合

第一人称视频在“是什么”上强，IMU 在“有没有持续在动、节奏怎样、什么时候停下”上强。Ego-Exo4D 甚至在设备能源预算内的在线识别作为独立 benchmark，原因正是穿戴设备不可能始终把所有高耗传感器全开。Ego-Exo4D 论文

已有多模态研究也支持“不要单押某一模态”：一项 20 类日常活动研究中，视频与 IMU 的融合平均准确率高于单独视频或单独 IMU；但该数字来自特定采集与数据集，不能直接当作本项目指标。可穿戴视觉-IMU 融合研究

对 vertical-fitness，优先级应是：IMU 先承担切段、周期和计数的交叉验证；视频承担器械、场景、动作候选；两者不一致时降低置信度而不是让其中一个“覆盖”另一个。这个组合既符合研究方向，也比双目改硬件更快形成可测的增益。

3. 双目相机：不是“多一个镜头就能看懂全身”

双目或双下视相机能带来深度和更稳定的近场几何，尤其有利于手、器械、握把、胸前到器械的相对运动，以及减少单目距离/尺度歧义。EgoExo-Fitness 使用多个下视相机来补足身体细节，证明这种采集思路有研究价值。

但双目无法让相机看到被身体挡住的腿、背部或骨盆，也不能自动获得与外部相机等价的全身关节角。它会引入同步、标定、低照度、功耗、佩戴位置一致性与隐私成本。我的判断是：双目更适合当作“有明确可见性目标”的硬件实验，例如提升拉力器、哑铃、杠铃近场互动的识别和计数；不应把它作为全量动作质量识别的承诺。

4. 用户标记与计划约束：不是补救，是最便宜的先验

若用户在训练开始前选择“今天练背” + “肱二头”，或从计划中确认“下一项是高位下拉4×10”，模型要从数十上百个动作里盲猜的问题，就转成在 3-5 个候选里做证据核验。这能实质性提升准确率，也让低置信结果能产出价值：系统不是问“你做了什么？”，而是问“第 2 组是高位下拉还是坐姿划船？”

计划约束必须是软先验，不能把计划当真值。用户会临时改动作、换器械、跳过组；系统应允许画面和传感器以高置信反驳计划，并把偏离记录为有价值的训练事实。

这条路线的产品设计包括：

- 开始训练时一键选择计划、训练部位或器械区；
- 每次识别只暴露低置信且影响总结的确认项；
- 用户确认的动作、器械和次数回写为本次真值，并成为个体校准数据；
- 计划提供候选集合、组数范围和顺序先验，不直接替模型“填答案”。

四、把“精确度”翻译成用户能拿到的服务

能力等级	最低输入条件	可对用户承诺的价值	输出表达
L0：训练存在	单目 1fps 图片或稀疏视频	自动记录训练时段、休息、场地/器械区，生成可编辑训练日记	“你在 18:20-19:05 完成了约 42 分钟训练。”
L1：训练语义	短视频/有序图片 + 音频，或计划先验	动作大类、器械、可能的动作候选、训练计划完成度	“这里更像拉类器械训练；在高位下拉/坐姿划船之间，请确认。”
L2：组与次数	视频 + IMU 或可靠音频事件 + 用户/计划约束	组边界、次数区间、节奏变化、休息质量	“这组估计 8 次，IMU 周期与视频一致；置信度中等。”
L3：动作确认	受控动作集 + 高质量连续视频 + IMU + 少量确认	具体动作、已完成组数、计划偏离、训练量	“计划的 4 组下拉已完成 3 组；第 4 组改成坐姿划船。”
L4：有限技术反馈	双目/双下视第一人称视角 + IMU；有动作专属标注	只针对设备实际可见的技术要点做提示，例如握距、器械路径、躯干节奏	“可见的握把路径不稳定；膝盖和深蹲深度不在当前视野内，因此不判断。”

关键原则：每条输出都带“证据来源、置信度、看不到什么”。这不是降低产品野心，而是让用户能判断该相信什么。特别是 L4，任何未经过动作专属验证的第一人称视觉都不应输出带伤害风险的姿势纠错建议；双目缓解深度歧义，不能把不可见的下肢、背部或关节角变得可见。

五、对当前仓库的直接建议

仓库已经从“整段拼图”走向 Gemini 原生视频 + 长视频窗口 + 可疑窗口复查 + 确定性合并，这是比 1fps 大拼图更合理的主线。实验平台 fitlab 也已经把 signals、ego、fusion 与 eval 分开，为多模态评测留好了位置。当前方案

下一步不建议先上双目硬件。建议按以下顺序投入：

1. 建立分级真值集。 同一批真实训练，标注状态边界、器械、动作大类、具体动作、次数、可见性和计划。不要只标最终动作名，否则无法知道误差来自切段、器械、候选还是计数。

2. 把计划约束接成软先验。在 fitlab/ego 的动作候选输入中显式注入当天计划、训练部位和已完成动作；产出同时保留“视觉候选”“计划候选”“冲突原因”。先验证它能在不提高硬件成本下改善多少。

3. 完成视频 + IMU 的时间对齐与融合评测。把组边界 F1、次数 MAE/OBO、动作 top-1/top-3、UNKNOWN 比例、用户确认次数与成本写进同一张表。先证明 IMU 对哪些动作族有增益，再决定器件与算法投入。

4. 把可见性设成硬门。Phase 1/2 输出增加 visibility：手/器械/上肢/躯干/下肢/全身各自是否足以判断。后续规则禁止在不可见关键点上生成技术建议。

5. 再做第一人称双目 POC。选 3 个高频且近场几何明确的动作族，比较单目与双目/双下视在器械识别、候选消歧、组边界、次数上的增量；不要只看“模型觉得更有信心”。

6. 建立小规模第一人称多传感采集集。在用户授权下，同步胸前/头戴第一人称相机、IMU 与训练计划/人工真值，服务三件事：建立评测真值、量化单目盲区、验证第一人称双目带来的净增益。无需依赖任何外部机位。

六、未来三种剧本

最可能：受约束的训练日志助手

产品默认以单目视频、音频和计划为输入，稳定交付训练片段、器械/动作候选、计划完成度和少量确认。IMU 逐步把分段与计数从“模型猜测”提高到可验证信号。它不是完美自动记录，却足以明显减少手记负担，并通过确认数据持续提高个人适配。

最危险：把动作质量承诺在不可见信息上

若产品把单目胸前相机包装成全身教练，会在深蹲、硬拉、肩胛控制等不可见关键点上自信误导用户。风险不只是准确率低，而是用户会把不可靠输出当训练建议。可见性门、UNKNOWN、证据回放和高风险提示禁用必须早于“更像教练”的文案。

最乐观：数据飞轮把单目体验抬高，硬件只用在高价值处

计划先验、用户确认、IMU 和少量第一人称双目采集可以让系统持续学会“这个人、这个健身房、这套器械、这份计划”的局部世界。双目不必成为第一版硬件前提，而应服务少数近场高精度场景与模型验证。届时，产品的差异不是声称看见一切，而是能根据证据质量，准确知道自己看见了多少。

七、建议的下一项实验：约束的真实增益，而不是模型展示

选择至少 30 段已标注真实训练视频，覆盖器械、自由重量与徒手三类；每段同步保存视频、音频、IMU、当天计划与人工真值。依次跑：

- A：当前视频模型；
- B：A + 短窗口证据聚合；
- C：B + 计划候选约束；
- D：C + IMU 边界/周期融合；
- E：在一个小子集上对比单目与第一人称双目/双下视的净增益。

验收不只看动作 top-1。至少同时报告：状态切分 F1、器械准确率、动作 top-1/top-3、次数 MAE 与 OBO、UNKNOWN 率、低置信时的正确率、每段需要用户确认的次数、端到端时延与成本。这样双目、人工标记与计划约束才能被放在同一张“每增加一份摩擦，换回多少确定性”的账本上。

信息来源

- Ego4D 官方文档：<<https://ego4d-data.org/docs/>>，访问于 2026-06-26。
- Ego4D, *Around the World in 3,000 Hours of Egocentric Video*：<<https://ai.meta.com/research/publications/ego4d-unscripted-first-person-video-from-around-the-world-and-a-benchmark-suite-for-egocentric-perception/>>，访问于 2026-06-26。
- Ego-Exo4D 官方文档：<<https://docs.ego-exo4d-data.org/>>，访问于 2026-06-26。
- Grauman et al., *Ego-Exo4D: Understanding Skilled Human Activity from First- and Third-Person Perspective s*：<https://openaccess.thecvf.com/content/CVPR2024/papers/Grauman_Ego-Exo4D_Understanding_Skilled_Human_Activity_from_First-_and_Third-Person_Perspectives_CVPR_2024_paper.pdf>，访问于 2026-06-26。
- Li et al., *EgoExo-Fitness: Towards Egocentric and Exocentric Full-Body Action Understanding*：<<https://arxiv.org/abs/2406.08877>>，访问于 2026-06-26。
- Furnari et al., *An Outlook into the Future of Egocentric Vision*：<<https://link.springer.com/article/10.1007/s11263-024-02095-7>>，访问于 2026-06-26。
- 现有仓库实验与设计：experiments/docs/视频输入策略-实验记录.md、experiments/方案与设计.md，读取于 2026-06-26。

方法说明

本报告采用横纵分析：纵向回看第一人称感知由手物交互、连续生活流到同步多视角健身研究的演进；横向比较单目、IMU、双目、用户标记、计划约束和外视角的能力边界。结论将公开研究的可行性与本仓库现有实验分开，不将跨数据集成绩当作产品准确率承诺。