

第一人称健身识别

论文证据、技术边界与产品路线

横纵分析深度研究 | 2026-06-28

vertical-fitness

执行摘要

这次调研最重要的结论，不是“第一人称动作识别能做到多少准确率”，而是：准确率取决于任务被定义在哪一层。

如果任务是识别“在健身房、正在使用拉力器、出现了一段持续运动”，第一人称相机可以提供稳定价值。如果任务是区分“高位下拉还是坐姿划船”，需要器械、握持、局部轨迹、训练计划和时序证据共同参与。如果任务是精确计数、判断全身姿态、推断真实肌肉激活，单目胸前 1fps 的信息通常不够。

本报告给出的产品判断是：

1. 稳定粒度应停在“场景/器械/动作家族/疑似组段”，具体动作按条件输出。在专门采集、连续视频、封闭类别的研究数据上，具体动作分类可以达到较高水平；这不是开放健身房长视频的稳定承诺。
2. 1fps 对静态语义仍有价值，对周期相位和瞬时边界不可靠。
它能支持器械、场景、持续活动与“疑似一组”；不能跨动作类型稳定支持精确次数。
3. 识别难度大致是：场景与大器械 < 手-物交互/动作家族 < 局部轨迹 < 第一人称人体全身姿态 < 个体肌肉激活。
“肌群”若指动作知识库里的目标肌群，可以在识别动作后映射；若指用户当下实际激活了哪些肌肉，RGB 视频不能可靠直接测量。
4. 双目首先补深度与遮挡消歧，不等于补全身体。两个相邻、重叠视野的镜头可提供同步视差、尺度和近场 3D；两个朝不同方向的镜头主要补覆盖。两种硬件目的不能混叫“双目”。
5. 最值钱的人工输入不是让用户重填训练日志，而是给系统一个高信息量锚点。优先级是：选择训练计划/目标 → 必要时确认动作名 → 标记组开始/结束；重量必须人工、器械接口或 OCR 获取，不能靠视觉猜。
6. 训练计划能把 open-world recognition 降成 closed-set verification，但只能是软约束。
系统还必须保留“计划外动作/无法判断”出口，否则计划会把错误变成高置信度错误。

七个问题的短答案

问题	结论
第一人称动作识别稳定到什么粒度？	稳定到场景、活动状态、器械/交互对象和动作家族；具体动作只在连续视频、可见证据充分、候选集有限时稳定。
低帧率什么可靠？	物体、器械、场景、姿态快照、持续活动占用率相对可靠；速度、方向反转、相位、短暂停顿、精确起止与次数不可靠。
器械、场景、轨迹、姿态、肌群谁容易？	大致依次变难；肌群只能作为动作后的知识映射，不能当成视觉直接测量。
1fps 能不能支撑组数/次数？	通用精确次数不能；持续数秒以上的慢动作在受约束条件下可试。可以支撑“疑似一组”和粗略组边界。
双目补什么？	重叠双目补深度、尺度、近场遮挡与 3D 轨迹；分向双摄补视角覆盖。都不能看见视野外身体。

问题	结论
用户手动标记补什么？	计划/目标最省交互且缩小全局候选；动作名纠正下游最多；开始/结束补时间边界；重量通常必须显式输入或接设备。
计划能否把 open world 变 closed set？	可以变成“候选生成 + 受约束验证”，但必须保留 UNKNOWN 和计划外检测。

一、研究脉络：Ego 数据集真正改变了什么

1. 从“整段活动”到“手、物体、状态变化”

早期第一人称研究已经发现，佩戴者本人往往不在画面里，最有辨识力的证据不是完整骨架，而是手、被操作物体、物体状态变化和相机自运动。Li、Ye 与 Rehg 在《Delving into Egocentric Actions》中系统比较了运动、物体、手、头部运动等中层线索，结论指向“多种 ego cue 的组合”，而非单一人体姿态。[1]

EPIC-KITCHENS 随后把任务标准化为 verb、noun 和 verb-noun action。它非常适合说明粒度问题：模型通常更容易认出“拿/放/打开”等动词，或某个被操作对象；当动词和名词必须同时正确时，组合动作明显更难。EPIC-KITCHENS-100 包含 97 个动词和 300 个名词，组合空间长尾而稀疏。[2]

Ego4D 进一步把第一人称理解拆成多个 benchmark：手-物交互、物体状态变化、短期预判、长视频定位、情景记忆等。[3] 这背后有一个非常产品化的事实：“发生了交互”“什么时候发生”“和什么交互”“动作名是什么”“结果状态是什么”是不同任务，不应被一个总准确率吞掉。

2. 从厨房走向熟练活动：健身的视角鸿沟

Ego-Exo4D 用同步第一人称和第三人称记录熟练活动，明确把第一视角与旁观视角当作不同分布。[4] 对健身最直接的证据来自 ECCV 2024 的 EgoExo-Fitness。该数据集为健身序列提供动作分类、两级时间边界、执行步骤、技术要点和质量评分，并使用两个下视 ego 相机捕捉更多身体细节。[5]

它的动作分类表非常有启发：

训练视角	测试第三人称	测试第一人称
只用第三人称训练	约 88%–93%	约 8%–16%
只用第一人称训练	约 9%	约 75%–80%
第一 + 第三人称训练	约 89%–90%	约 73%–79%

这些数值不是产品准确率，但它们证明了两件事。第一，视角域差异足以让一个在第三人称上很强的模型几乎失效。第二，在专门采集的封闭动作集里，用匹配视角的数据训练后，第一人称动作分类可以做到可用水平。这里的限定条件不能省略：EgoExo-Fitness 是同步采集、类别已知、边界有标注、硬件有两个下视 ego 视角的研究数据。真实胸前单目长视频还会增加遮挡、走动、休息、换器械、陌生健身房、计划外动作与类别长尾。因此，论文里的 75%–80% 更适合被理解为“匹配数据与封闭任务的可达性证据”，不是线上 SLA。

3. 研究前沿已经从“是什么”走向“什么时候、做得怎样”

近年来研究继续向时间定位、跨视角验证和动作质量评估延伸。但这些能力所需的监督越来越重：完整时间边界、子步骤、技术要点、质量标签，甚至同步第三人称真值。EgoExo-Fitness 的数据设计本身就是答案——要判断“做得怎样”，研究团队没有只靠一段未经标注的第一人称视频。

因此，第一人称健身产品不应把 action classification、temporal localization、repetition counting 和 action quality assessment 合并成一句“识别动作”。它们的可观测性、标注成本和失败方式完全不同。

二、第一人称下，动作识别通常能稳定到什么粒度

1. 一个可落地的五层粒度

层级	输出示例	胸前第一人称可观测性	建议产品承诺
L0 场景/状态	健身房、器械区、休息、移动	高	可以稳定输出
L1 器械/交互	拉力器、哑铃、杠铃；握住直杆	中高，取决于遮挡和尺度	作为主输出
L2 动作家族	推/拉/蹲/髋铰链；垂直拉/水平拉	中	多帧一致时输出
L3 具体动作	高位下拉、坐姿划船、三头下压	中低到中，强依赖候选集和可见证据	候选 + 置信 + 可确认
L4 质量/生物力学	深蹲深度、脊柱中立、目标肌实际激活	低或不可观测	只对已验证、可见的局部指标输出

“稳定”不应只看 top-1，而应同时满足跨用户、跨健身房、跨佩戴位置和连续长视频中的校准。第一人称综述反复指出，相机运动、主体部分不可见、手和物体遮挡、场景域迁移是核心困难。[6] 所以产品上更诚实的答案是：动作家族是默认稳定粒度，具体动作是条件能力。

2. 哪些动作容易，哪些动作天然难

容易的动作通常具备至少两项强证据：独特器械、独特握把、明显身体朝向、稳定周期、与计划高度一致。例如拉力器直杆三头下压，若直杆、滑轮方向、手部位置和向下轨迹都可见，候选空间很小。

难例通常来自同器械、同姿态、局部轨迹相似：坐姿推胸与坐姿划船、高位下拉与某些高位划船、飞鸟与推胸、不同握距或把手变体。1fps 又可能恰好只采到动作中间位置，使方向相反的动作呈现相似快照。

因此，类别体系不应是一张扁平的几百动作表。更合适的是层级分类：

场景 → 器械族 → 身体姿态 → 运动方向/交互模式 → 具体动作候选

这也让低置信结果仍有价值：具体动作分不出时，系统仍可记录“拉力器水平拉类，疑似一组”。

三、低帧率下：可靠信息与不可靠信息

1. 1fps 保留的是“状态”，丢失的是“相位”

动作识别模型常用稀疏采样以减少冗余，但研究也指出，均匀采样会漏掉关键瞬间；运动引导采样、显著片段采样和全分辨率计数方法的存在，恰好说明采样策略会改变结果。[7][8][9]

在 1fps 下，相对可靠的是：

- 场景、区域和大器械；
- 用户是否持续待在同一器械前；
- 手是否多次出现在某个握把附近；
- 坐/站/躺等粗姿态快照，前提是身体可见；
- 一段时间内“持续活动”与“持续静止”的占用模式；
- 器械切换、明显移动和较长休息。

不可靠的是：

- 快速动作的方向反转与离心/向心相位；
- 短暂停顿、未完成的最后一次、借力与小幅度作弊；
- 精确起止时间；
- 速度、爆发性、节奏变化；
- 需要连续关节轨迹的动作质量；
- 由周期相位推导的精确次数。

低帧率不是“准确率统一下降一点”，而是让一类变量继续可见、另一类变量从根上不可辨识。

2. 为什么 1fps 通用计数会混叠

重复计数依靠周期。RepNet、Countix、RepCount 等工作都以连续视频中的时序自相似或周期表征为核心；后续工作还专门选择合适采样率，或保留完整时间分辨率以避免漏掉重复。[10][11][12]

阻力训练的一次重复可能从约 2 秒到 10 秒以上；实验中也常比较 2 秒/次、4 秒/次、8 秒/次等节奏。[13] 以 2 秒/次为例，1fps 理论上每个周期只有两个样本，刚好贴近奈奎斯特下限。实际还有不规则节奏、相机自运动、掉帧、遮挡与采样相位偏差，两个样本不足以稳定区分一个完整周期、半周期和方向反转。若动作接近 1 秒/次，1fps 甚至可能每次都拍到相似相位，看起来几乎不动。

所以结论应分三档：

任务	1fps 判断	条件
精确次数	不应通用承诺	只有慢节奏、幅度大、轨迹清楚、候选动作已知时可实验性输出
次数区间	有条件可做	结合组时长、动作先验、可见周期和 IMU，输出如 8–12 次
疑似一组	可做且有产品价值	同器械停留 + 连续运动段 + 前后休息/调节行为

“疑似一组”不要求恢复每个周期。它是一个事件检测问题：在同一器械交互上下文中，出现一段连续、相对规律的活动，并被休息或场景切换包围。即使 1fps 不足以数清 10 次，仍可能把 30 秒训练段从 90 秒器械停留中找出来。

3. 组数也不是次数的简单上位词

若组间休息足够长，1fps 对组数通常比对次数友好。但真实健身房存在递减组、超级组、组内暂停、调重量、与人聊天、短暂离开等情况。系统应输出组事件及边界置信区间，而不是伪精确到秒：

14:03–14:04 之间出现一段疑似训练；边界误差约 ± 3 秒；动作候选为三头下压/直臂下压。

IMU 在这里比第二个相邻 RGB

镜头更有可能带来性价比：它能连续观察佩戴者运动强度和周期，不受视觉遮挡影响。视觉负责“是什么”，IMU 负责“是否持续运动与节奏如何”。

四、健身房里，模型更容易识别什么

1. 难度排序

在胸前第一人称、尤其 1fps 条件下，合理的经验排序是：

场景/大器械 → 交互对象与握把 → 动作家族 → 局部轨迹 → 自身全身姿态 → 实际肌肉激活

这不是所有样本的绝对排序。例如一枚小哑铃可能被身体遮住，而镜子里恰好能看到姿态。但作为系统设计优先级，这个排序与第一人称研究的物体中心、手-物交互和主体不可见问题一致。[1][6][14]

2. 器械与场景为何更容易

它们具有稳定外观，跨帧持续存在，不依赖瞬时运动相位。器械还能强力缩小动作候选：看到跑步机、史密斯机、拉力器或坐姿推胸机，动作空间已从数百类缩到一个小子集。

但“器械识别”也要区分层级。认出“拉力器”比认出具体把手、滑轮高度和配重数字容易。后者受到分辨率、反光、遮挡和相机朝向影响。

3. 轨迹和姿态为何更难

轨迹需要连续、对应一致的点。1fps 的手或器械位置序列可能发生混叠；胸前相机又随躯干移动，使图像坐标中的运动同时包含器械运动和相机自运动。

姿态更难，因为佩戴者身体往往只露出手臂、腿部边缘或衣服局部。EgoExo-Fitness

使用两个下视第一人称相机来捕捉更多身体细节，本身说明单一普通视角不足。[5] Ego3DPose、S2DHand 和 egocentric stereo pose 研究也把单目深度歧义、有限视野与遮挡列为核心动机。[15][16][17]

4. “肌群”必须拆成两个概念

如果“识别肌群”是指：识别出动作后，从训练知识库映射主要/次要目标肌群，那么它是一个可做的语义推断：

动作 = 卧推 → 主要目标肌群 = 胸大肌；协同肌 = 三头肌、三角肌前束。

如果它指：这个用户这一组实际激活了哪些肌肉、激活比例多少，则不是普通 RGB

视觉能稳定直接测量的变量。肌肉激活通常由表面肌电图测量；即便 sEMG

本身也受电极位置、串扰、肌肉长度、收缩速度、负荷和疲劳等影响，需要谨慎解释。[18][19]

卧推综述也显示，负荷、速度、稳定性和疲劳会改变肌电活动。[20]

已有《Muscles in Action》等研究尝试从视频预测肌电，是有价值的前沿探索，但其数据依赖同步视频与 EMG，不能被等同于“任意胸前视频可读出个体肌肉激活”。[21]

产品文案应说“该动作通常主要训练胸肌”，不应说“检测到你的胸肌激活 82%”。

五、双目相机到底补什么

1. 先区分两种“双摄”

设计	光轴/视野	主要收益	主要代价
重叠双目 stereo	两镜头看同一片区域，有已知基线	视差深度、绝对尺度、遮挡消歧、近场 3D 手/器械轨迹	标定、同步、纹理依赖、算力、功耗；视野并未翻倍
分向双摄 multi-view	两镜头朝不同方向或一个前向一个下视	扩大覆盖，看到更多手臂/躯干/器械	无法对不重叠区域直接三角测深，融合更复杂

如果产品问题是“握把离身体多远、左右手是否处于相同深度、器械杆是否朝向相机运动”，重叠双目有明确价值。如果问题是“胸前前向镜头看不到腿”，需要的是下视/广角覆盖，而不是只在同一朝向增加一个镜头。

2. 论文支持什么

Ego3DPose 明确利用 binocular egocentric views 中的 stereo correspondence 与强透视线索恢复 3D 姿态。[15] S2DHand 将单视角的有限视野和深度歧义作为双视角适配的主要动机。[16] CVPR 2024 的 egocentric stereo pose 工作进一步把场景深度重建与时序关节查询结合。[17]

这些论文支持的结论是：双目能提升 3D 几何感知，尤其近场身体/手部与场景关系。它们不支持“加一个镜头就能稳定识别所有健身动作”。原因很直接：

- 两个镜头都没看到的部位仍不存在；
- 低纹理、反光金属、重复结构会影响立体匹配；
- 胸前基线有限，远距离深度精度下降；
- 柔性衣物、快速运动与遮挡仍然困难；
- 1fps 的时间混叠不会被同步双目自动修复。

3. 硬件决策

双目 POC 应围绕明确失败族，而不是泛测总准确率：

1. 单目错误是否集中在深度方向相反、近场遮挡或握把关系？
2. 重叠 stereo 与前向 + 下视 multi-view，哪一个解决更多真实错误？
3. 增益最终是否体现为动作 top-1 提升、组边界误差下降或用户确认次数减少？
4. 与 IMU、计划先验相比，每单位功耗和硬件成本的收益如何？

如果主要错误来自“动作不在视野、帧率太低、类别开放、没有计划上下文”，双目不会是最优先解。

六、用户手动标记应该补什么

人工输入的价值可以用一句话衡量：一次交互能消除多少下游不确定性。

人工输入	解决的问题	下游杠杆	推荐方式
整次训练目标/计划	缩小全程候选、提供顺序和组数先验	最高	训练前一键选择
动作名确认	消除同器械相似动作歧义；可形成个性化样本	很高	系统给 2-3 个候选时点一次
组开始/结束	修正时间边界与组数	中高	只在自动切段失败的动作族启用
重量	视觉通常看不清配重片/插销，且哑铃外观可能相似	独立高价值字段	语音、快捷数字、器械/NFC/蓝牙、OCR 辅助
每次重复	成本极高，破坏训练体验	低	不推荐

最好的顺序通常是“计划在前、确认在后”。计划在推理前缩小全局候选；动作确认只处理系统真正犹豫的局部难例。用户确认的数据还可用于用户级、健身房级或器械级少样本适配。少样本和跨域研究表明，少量目标域样本能改善新用户/新环境适配，但实际收益取决于类别和域差异。[22][23]

重量是特殊字段。它对训练价值很高，却不是动作识别的自然副产物。系统应该明确承认信息源：

动作来自视觉；组段来自视觉 + IMU；重量来自用户、器械接口或 OCR。

把这些来源混在一个“AI 自动识别”标签下，会让用户无法判断哪里值得信。

七、训练计划能否把 open world 变成 closed-set verification

1. 可以，而且这是最便宜的准确率杠杆

标准动作分类假设一个固定类别集合，但真实活动具有组合性和开放性。Scott 等人在 EPIC-KITCHENS 上专门研究 few/zero-shot 与 open-set egocentric action recognition，指出固定集合假设在实际中并不充分。[24]

若用户选择“Pull Day

A：高位下拉、坐姿划船、面拉、弯举”，系统无需每个窗口都在几百个动作中开放猜测。它可以执行：

1. 根据当前计划、进度、器械和历史生成 3-5 个候选；
2. 对每个候选计算视觉/IMU 证据；
3. 验证“是否与某个计划动作一致”；
4. 若都不一致，输出计划外动作或 UNKNOWN。

这确实把问题从 open-world classification 降成了 closed-set verification with rejection。

2. 为什么不能做成硬规则

用户会换器械、替换动作、跳过一组、插入热身或临时做计划外动作。如果系统用计划覆盖视觉反证，就会出现“计划里写了高位下拉，所以任何拉力器画面都是高位下拉”的确认偏误。

正确的概率结构是：

后验 ∝ 视觉/IMU 似然 × 计划先验

计划提高候选概率，但不能把其他类别概率归零。系统必须保留三个出口：

- planned_action_verified
- unplanned_action_detected
- insufficient_evidence

3. 计划约束不仅缩小类别，还约束时间结构

计划可以提供动作顺序、预计组数、典型休息时长和器械区域。上下文与顺序约束在复杂活动识别中长期被用于减少局部歧义。[25][26] 对健身而言，它能帮助回答：

- 当前更可能是上一动作的最后一组，还是下一动作的热身？
- 两段短运动中间只有 8 秒，是组内暂停还是新一组？
- 视觉在两个动作间摇摆时，哪个更符合当前计划进度？

但最终评测必须包含计划偏离样本。否则系统只会在“用户完全按计划训练”的理想数据上看起来很准。

八、横向比较：四条可行路线

路线	最擅长	不能解决	成本/摩擦	推荐优先级
单目 1fps + 计划	场景、器械、动作候选、疑似组	精确次数、速度、全身质量	最低	P0
单目连续视频 + 计划	具体动作、局部轨迹、粗次数	被遮挡身体、真实肌肉激活	中等算力/带宽	P0/P1
单目 + IMU + 计划	组边界、周期、运动/休息连续性	视觉语义缺失、全身姿态	低到中	P1
双目/多视角 + IMU + 计划	深度、覆盖、局部 3D、难例消歧	视野外身体、开放类、肌肉激活	最高硬件成本	仅按失败族 POC

这张表指向一个不太戏剧化、但很务实的选择：先加上下文和时间证据，再加相机。

训练计划几乎不增加硬件成本，却能缩小候选空间。IMU 是连续高频信号，直接对应 1fps 最缺的时间结构。双目只有在错误分析证明“深度或遮挡是主要瓶颈”后才值得进入。

九、建议的产品能力阶梯

L0：自动训练时间线

输出训练开始/结束、器械停留、休息/移动、疑似训练段。即使不输出动作名，也能帮助用户回忆并减少日志填写。

L1：计划核验

用户选择当天计划，系统对疑似组段验证计划动作，输出“按计划完成/疑似替换/无法确认”。这是最应该优先做的闭环。

L2：动作候选与组数

在器械和时序证据充分时输出具体动作；否则停在动作家族。组数输出整数，但每组边界带时间区间和置信来源。

L3：次数区间与自动确认

连续视频或 IMU 证据充分时输出精确次数；1fps

仅输出区间或未知。用户确认一次后，系统更新整组和计划完成度。

L4：有限动作质量

只对已经证明可见、可测、可复现的指标输出，例如某些器械杆路径、节奏一致性或左右轨迹差异。不要从胸前盲区推断深蹲深度、脊柱状态或个体肌肉激活。

十、下一轮实验：用数据决定加什么

实验 A：1fps 能力边界

选择至少 8 个动作家族、30 名用户、多个健身房与佩戴偏差。由同一原视频生成 30fps、5fps、2fps、1fps 四档输入，分别评测：

- 场景/器械 top-1；
- 动作家族 macro-F1；
- 具体动作 top-1/top-3；
- 组事件 F1 与边界误差；
- 次数 MAE、off-by-one；
- 置信度校准 ECE。

这样才能回答“1fps 哪些信息可靠”，而不是靠一条视频的成功或失败。

实验 B：计划约束与拒识

四个条件使用同一批视频：

- open world，无计划；
- 只给目标肌群；

- 给当日动作候选和顺序；
- 给候选，但包含 20% 计划外动作。

核心指标除准确率外，还要看计划外召回率、UNKNOWN 精确率和错误高置信比例。

实验 C：人工标记的信息增益

比较四种最小交互：选择计划、确认动作、点组边界、输入重量。指标不是字段正确率，而是每次点击带来的下游错误减少量，以及每次训练平均交互次数。

实验 D：双目 vs 多视角 vs IMU

同一硬件原型同时采集前向单目、重叠双目、前向 + 下视和 IMU。针对已知混淆族评测：

- 深度方向相反动作；
- 手/把手近场遮挡；
- 胸前视野缺失下肢；
- 1fps 计数与组边界。

若双目的增益主要来自第二视角覆盖，而不是立体深度，就应选择更便宜的分向双摄；若 IMU 已解决大部分周期问题，就不应为计数上双目。

十一、最终判断

第一人称健身识别的产品机会，不在于复制一个第三人称 AI 教练，而在于利用第一人称最独特的证据：我到了哪里、我面对什么器械、我和什么交互、我在什么时候持续训练。

研究界已经证明，匹配视角的数据、连续视频和封闭动作集可以把具体动作分类推到可用水平；同样也证明，视角迁移、时间定位、精确计数和动作质量并不会自动随模型变大而消失。

因此最合理的系统不是“一次猜出完整训练日志”，而是一条逐层收敛的证据链：

1fps 识别场景与疑似组 → 器械和计划生成候选 → 连续视频/IMU 验证时序 → 用户只确认高价值歧义
→ 双目只解决被数据证明的深度与遮挡问题。

这样，即使系统只知道“拉力器上发生了一组垂直拉类动作”，它也能给用户诚实价值；证据足够时再升级成“高位下拉，3 组，每组约 10 次”。能力分层不是给技术找借口，而是把每一档精度都兑换成可用产品。

参考文献

1. Li, Y., Ye, Z., & Rehg, J. M. “Delving into Egocentric Actions.” CVPR 2015.
<<https://pmc.ncbi.nlm.nih.gov/articles/PMC4784702/>>
2. Damen, D. et al. “Rescaling Egocentric Vision: Collection, Pipeline and Challenges for EPIC-KITCHENS-100.” IJCV 2022. <<https://epic-kitchens.github.io/2021>>

3. Grauman, K. et al. "Ego4D: Around the World in 3,000 Hours of Egocentric Video." CVPR 2022. <<https://ego4d-data.org/>>
4. Grauman, K. et al. "Ego-Exo4D: Understanding Skilled Human Activity from First- and Third-Person Perspectives." CVPR 2024. <https://openaccess.thecvf.com/content/CVPR2024/html/Grauman_Ego-Exo4D_Understanding_Skilled_Human_Activity_from_First-_and_Third-Person_Perspectives_CVPR_2024_paper.html>
5. Li, Y.-M. et al. "EgoExo-Fitness: Towards Egocentric and Exocentric Full-Body Action Understanding." ECCV 2024. <https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/03057.pdf>
6. Núñez-Marcos, A. et al. "Egocentric Vision-based Action Recognition: A Survey." Neurocomputing 2022. <<https://doi.org/10.1016/j.neucom.2021.11.081>>
7. Korbar, B., Tran, D., & Torresani, L. "SCSampler: Sampling Salient Clips from Video for Efficient Action Recognition." ICCV 2019. <<https://arxiv.org/abs/1904.04289>>
8. Zhi, Y. et al. "MGSampler: An Explainable Sampling Strategy for Video Action Recognition." ICCV 2021. <<https://arxiv.org/abs/2104.09952>>
9. Liu, X. et al. "No Frame Left Behind: Full Video Action Recognition." CVPR 2021. <<https://arxiv.org/abs/2103.15395>>
10. Dwibedi, D. et al. "Counting Out Time: Class Agnostic Video Repetition Counting in the Wild." CVPR 2020. <https://openaccess.thecvf.com/content_CVPR_2020/html/Dwibedi_Counting_Out_Time_Class_Agnostic_Video_Repetition_Counting_in_the_CVPR_2020_paper.html>
11. Zhang, H. et al. "Repetitive Activity Counting by Sight and Sound." CVPR 2021. <https://openaccess.thecvf.com/content/CVPR2021/papers/Zhang_Repetitive_Activity_Counting_by_Sight_and_Sound_CVPR_2021_paper.pdf>
12. Sinha, D. et al. "Full Resolution Repetition Counting." 2023. <<https://arxiv.org/abs/2305.13778>>
13. Wilk, M. et al. "Does Tempo of Resistance Exercise Impact Training Volume?" Journal of Human Kinetics 2018. <<https://pmc.ncbi.nlm.nih.gov/articles/PMC6006544/>>
14. Shiota, T. et al. "Egocentric Action Recognition by Capturing Hand-Object Contact and Object State." WACV 2024. <https://openaccess.thecvf.com/content/WACV2024/html/Shiota_Egocentric_Action_Recognition_by_Capturing_Hand-Object_Contact_and_Object_State_WACV_2024_paper.html>
15. Tome, D. et al. "Ego3DPose: Capturing 3D Cues from Binocular Egocentric Views." 2023. <<https://arxiv.org/abs/2309.11962>>
16. Liu, S. et al. "Single-to-Dual-View Adaptation for Egocentric 3D Hand Pose Estimation." CVPR 2024. <https://openaccess.thecvf.com/content/CVPR2024/papers/Liu_Single-to-Dual-View_Adaptation_for_Egocentric_3D_Hand_Pose_Estimation_CVPR_2024_paper.pdf>
17. Akada, H. et al. "3D Human Pose Perception from Egocentric Stereo Videos." CVPR 2024. <https://openaccess.thecvf.com/content/CVPR2024/papers/Akada_3D_Human_Pose_Perception_from_Egocentric_Stereo_Videos_CVPR_2024_paper.pdf>

18. Farina, D., Merletti, R., & Enoka, R. "The Extraction of Neural Strategies from the Surface EMG." *Journal of Applied Physiology* 2004. <<https://doi.org/10.1152/jappphysiol.01070.2003>>
19. Disselhorst-Klug, C., & Williams, S. "Surface Electromyography Meets Biomechanics." *Frontiers in Neurology* 2020. <<https://doi.org/10.3389/fneur.2020.603550>>
20. Stastny, P. et al. "A Systematic Review of Surface Electromyography Analyses of the Bench Press Movement Task." *PLOS ONE* 2017. <<https://pmc.ncbi.nlm.nih.gov/articles/PMC5295722/>>
21. Ghosh, B. et al. "Muscles in Action." *ICCV* 2023. <<https://arxiv.org/abs/2212.02978>>
22. Gong, T. et al. "MMG-Ego4D: Multi-Modal Generalization in Egocentric Action Recognition." *CVPR* 2023. <https://openaccess.thecvf.com/content/CVPR2023/papers/Gong_MMG-Ego4D_Multimodal_Generalization_in_Egocentric_Action_Recognition_CVPR_2023_paper.pdf>
23. Hatano, M. et al. "Multimodal Cross-Domain Few-Shot Learning for Egocentric Action Recognition." *ECCV* 2024. <<https://arxiv.org/abs/2405.19917>>
24. Scott, T. R. et al. "Unifying Few- and Zero-Shot Egocentric Action Recognition." *CVPR Workshops* 2020. <<https://arxiv.org/abs/2006.11393>>
25. Koppula, H. S., & Saxena, A. "Learning Spatio-Temporal Structure from RGB-D Videos for Human Activity Detection and Anticipation." *ICML* 2013. <<https://proceedings.mlr.press/v28/koppula13.html>>
26. Wu, C. et al. "Deep Action- and Context-Aware Sequence Learning for Activity Recognition and Anticipation." 2016. <<https://arxiv.org/abs/1611.05520>>